

一种基于可微一致性投影的临床事件时序推理及逻辑校准方法

发明人：AI4S 团队

2026 年 2 月 2 日

1 著录项目

- **发明名称：**一种基于可微一致性投影的临床事件时序推理及逻辑校准方法
- **技术领域：**自然语言处理（NLP）、医疗信息学、神经符号人工智能

2 背景技术与技术问题

2.1 现有技术

在从非结构化电子病历（EHR）中抽取纵向临床事件（如：诊断、治疗、进展）时，现有技术主要分为两类：

1. **规则与模板匹配：**依赖大量人工定义的正则表达式。
2. **基于统计的大语言模型（SFT/RLHF）：**使用目前主流的 Transformer 架构进行监督微调（SFT）。

2.2 技术缺陷

现有的大语言模型（LLMs）在处理长序列时序逻辑时，存在显著的“**时序幻觉**”问题（如图 1 所示）：

- **统计而非逻辑：**模型仅学习了词汇共现的概率分布，而未真正掌握“时间拓扑结构”。
- **违反传递性：**生成的事件序列经常违反逻辑传递性。
- **无法零样本迁移：**依赖海量领域数据进行训练。

FIG. 1: SCHEMATIC DIAGRAM OF TEMPORAL HALLUCINATION IN AI MODEL PREDICTIONS




图 1: 时序幻觉示意图：现有模型常生成违反传递性的逻辑闭环

2.3 技术问题

本发明要解决的核心技术问题是：如何在**不依赖海量逻辑标注数据**的前提下，使神经网络模型能够内化“**时间拓扑逻辑**”作为一种归纳偏置，从而生成符合因果律和传递性的临床事件序列。

3 技术方案

3.1 总体思路

本发明提出了一种**生成-验证-投影**（GVP）架构。与现有技术不同，本发明不仅仅是在推理端进行修正，而是引入了一个“**可微一致性层**”，将逻辑约束（传递性、反对称性）直接嵌入到模型的**训练目标**中，迫使模型学习“合法的时间流形”。

3.2 与现有技术的区别

- **对比 SFT:** SFT 仅最小化“预测下一个词”的交叉熵损失，本发明增加了“逻辑一致性损失”(如图 2 数据所示，SFT 仅 18.5% F1，本发明达 84.2%)。
- **对比 RLHF:** RLHF 依赖稀疏的奖励信号，优化困难；本发明的投影层是可微的，能够提供密集的梯度信号，训练效率更高。




图 2: 性能对比: MedTime (GVP) 与基线 SFT 的 F1 分数显著差异

3.3 系统架构图




图 3: GVP 神经符号协同系统架构图

3.4 核心模块详解

3.4.1 模块一：模式约束生成器 ($\mathcal{G}$)

- **功能：** 负责从文本中提取原始的事件提及及其属性。
- **实现：** 基于 Encoder-Decoder 架构，但在解码端引入了 Schema 约束，确保输出格式（如 JSON）的结构合法性，为后续的逻辑计算提供基础。

3.4.2 模块二：成对校准器 ($\mathcal{V}$)

- **功能：** 这是一个轻量级的判别模块，用于预测任意两个事件 (e_i, e_j) 之间的相对时序关系 (Before, After, Overlap)。

- **创新点：**它不生成文本，而是输出一**一致性权重矩阵** W_{ij} ，作为逻辑梯度的“门控机制”。

3.4.3 模块三：可微一致性层 ($\mathcal{P}$)

- **功能：**（本发明核心创新点）。这是一个嵌入在神经网络末端的逻辑层（机制如图4所示）。
- **机制：**它定义了一个“逻辑损失函数” $\mathcal{L}_{logic}$ ，该损失函数基于图论中的传递闭包性质。
- **训练过程：**

$$\mathcal{L}_{total} = \mathcal{L}_{ce} + \lambda \cdot \mathcal{L}_{logic}(Project(\mathcal{G}, \mathcal{V})) \quad (1)$$

在训练过程中，如果生成器生成的序列违反了由校准器定义的拓扑结构，该层会反向传播梯度，直接更新 $\mathcal{G}$ 的参数。

- **效果：**这种机制赋予了模型“归纳偏置”，使其在推理阶段即使没有显式的约束，也能自然生成符合逻辑的结果。




图 4: 可微一致性层工作原理图

4 有益效果

1. **内化逻辑推理能力**：通过可微投影训练，模型不再是死记硬背时间点，而是学会了“相对时序推理”。实验表明，在 MedTime-CN 基准上，时序 F1 分数达到 **84.2%** (SOTA)。
2. **卓越的跨语言/跨领域迁移能力**：由于“时间逻辑”是普世的，不依赖于具体语言。本发明在中文数据上训练的逻辑模块，能够零样本迁移到英文数据集 (E3C)，F1 分数达到 **50.0%**，是传统 SFT 方法的两倍以上。
3. **数据高效性**：传统的 SFT 需要数万条数据才能拟合长尾分布；本发明利用逻辑归纳偏置，仅需少量样本即可达到极高的逻辑一致性，大幅降低了医疗数据的标注成本。

5 具体实施方式

5.1 实施例 1：云端临床科研辅助系统

系统部署在医院私有云。输入为非结构化的出院小结。

1. **预训练阶段**：使用本发明的 GVP 架构在通用医疗语料上进行预训练，注入时序逻辑偏置。
2. **微调阶段**：使用医院少量的标注数据 (<100 例) 进行适配。
3. **推理阶段**：模型输出结构化的患者时间轴，直接用于队列研究的入组筛选。

5.2 实施例 2：跨语言病历结构化

应用于国际多中心临床试验。直接利用在中文数据上训练好的 GVP 模型，处理英文或法文的病例数据，无需针对每种语言重新进行大规模逻辑训练，显著缩短了多中心数据清洗的周期。

6 权利要求书草案

1. 一种基于可微一致性投影的临床事件时序推理方法，其特征在于，包括：
 - 步骤 S1：利用模式约束生成器，从医疗文本中生成候选事件序列；
 - 步骤 S2：利用成对校准器，预测所述候选事件之间的相对时序关系权重；
 - 步骤 S3：通过可微一致性层，计算违反逻辑传递性的拓扑损失，并将其作为训练目标的一部分；

- 步骤 S4: 基于所述拓扑损失联合更新生成器与校准器的参数, 使模型内化时序逻辑。
2. 如权利要求 1 所述的方法, 其特征在于, 所述可微一致性层在训练阶段引入归纳偏置, 使得模型在推理阶段能够直接生成符合时序拓扑的序列。